

1. Núcleo Conceptual: FRP vs. FRM

El objetivo central de la econometría es **estimar la Función de Regresión Poblacional (FRP) a partir de una Función de Regresión Muestral (FRM)**.

[Población (Inobservable)]

$$\text{FRP: } E(Y|X) = \beta_1 + \beta_2 X$$

Muestreo aleatorio



[Muestra (Observable)]

$$\text{FRM: } \hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

Función de Regresión Poblacional (FRP): Determina el valor promedio de la variable dependiente Y condicionado a valores dados del regresor X . [PDF + 1](#)

- Forma estocástica: $Y_i = E(Y|X_i) + u_i = \beta_1 + \beta_2 X_i + u_i$
[PDF + 1](#)
- u_i (**Error poblacional**): Es la desviación del individuo respecto a la media poblacional ($u_i = Y_i - E(Y|X_i)$). Es **inobservable**. [PDF](#)

Función de Regresión Muestral (FRM): Recta estimada a partir de los datos muestrales. Varía de muestra en muestra. [PDF + 2](#)

- Estimación: $\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$
[PDF](#)
- Forma con residuo: $Y_i = \hat{Y}_i + \hat{u}_i$
[PDF](#)
- $\hat{u}_i$ (**Residuo muestral**): Distancia entre el valor observado Y_i y el valor ajustado $\hat{Y}_i$ ($\hat{u}_i = Y_i - \hat{Y}_i$). Es **observable y calculable**. [PDF](#)

2. Desarrollo Algebraico: Derivación de Estimadores MCO (OLS)

El método de **Mínimos Cuadrados Ordinarios (MCO)** minimiza la Suma de Residuos al Cuadrado (SRC): [PDF](#)

$$\min_{\hat{\beta}_1, \hat{\beta}_2} S(\hat{\beta}_1, \hat{\beta}_2) = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$$

Condiciones de Primer Orden (CPO)

1. Respecto a $\hat{\beta}_1$:

$$\frac{\partial S}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0 \implies \sum_{i=1}^n Y_i - n\hat{\beta}_1 - \hat{\beta}_2 \sum_{i=1}^n X_i = 0$$

Dividiendo todo por n :

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$$

2. Respecto a $\hat{\beta}_2$:

$$\frac{\partial S}{\partial \hat{\beta}_2} = -2 \sum_{i=1}^n X_i (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0 \implies \sum_{i=1}^n X_i \hat{u}_i = 0$$

Sustituyendo $\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$:

$$\sum_{i=1}^n X_i ((Y_i - \bar{Y}) - \hat{\beta}_2 (X_i - \bar{X})) = 0$$

Dado que $\sum (X_i - \bar{X})(Y_i - \bar{Y}) = \sum X_i (Y_i - \bar{Y})$:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}} = \frac{\widehat{\text{Cov}}(\mathbf{X}, \mathbf{Y})}{\widehat{\text{Var}}(\mathbf{X})} = r_{xy} \frac{s_y}{s_x}$$

Propiedades Algebraicas de los Residuos

(Se cumplen siempre por construcción matemática, sin importar si el modelo teórico es correcto): [PDF](#)

- $\sum_{i=1}^n \hat{u}_i = 0 \implies \bar{\hat{u}} = 0$ (la media muestral de los residuos es cero siempre que haya constante).
- $\sum_{i=1}^n X_i \hat{u}_i = 0 \implies \widehat{\text{Cov}}(X, \hat{u}) = 0$ (la covarianza muestral entre el regresor y los residuos es nula).
- $\sum_{i=1}^n \hat{Y}_i \hat{u}_i = 0$ (los valores predichos son ortogonales a los residuos).
- El punto $(\bar{X}, \bar{Y})$ pertenece siempre a la recta de regresión: $\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}$.

3. Descomposición de la Varianza y Bondad de Ajuste (R^2)

Partiendo de $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + \hat{u}_i$, elevando al cuadrado y aplicando $\sum \hat{u}_i(\hat{Y}_i - \bar{Y}) = 0$:

$$\text{STC} = \text{SEC} + \text{SRC}$$

Componente	Definición	Fórmula
STC	Suma Total de Cuadrados (variación total de Y)	$\sum_{i=1}^n (Y_i - \bar{Y})^2$
SEC	Suma Explicada de Cuadrados (variación explicada por el modelo)	$\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$
SRC	Suma de Residuos al Cuadrado (variación no explicada)	$\sum_{i=1}^n \hat{u}_i^2$

...

- Coeficiente de Determinación (R^2):

$$R^2 = \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}}, \quad 0 \leq R^2 \leq 1$$

- En regresión lineal simple: $R^2 = (r_{xy})^2$.

4. Propiedades Estadísticas y Teorema de Gauss-Markov (MELI / BLUE)

Bajo los supuestos clásicos de Gauss-Markov: [PDF](#)

1. **Linealidad en los parámetros:** $Y = \beta_1 + \beta_2 X + u$.
2. **Muestreo aleatorio:** Muestra i.i.d. de tamaño n .
3. **Variación en X :** $\sum (X_i - \bar{X})^2 > 0$ (no colinealidad perfecta).
4. **Media condicional nula (Exogeneidad estricta):** $E(u|X) = 0 \implies$ Garantiza insesgadez: $E(\hat{\beta}_2) = \beta_2$.
5. **Homocedasticidad:** $\text{Var}(u|X) = \sigma^2$ (varianza constante del error).
6. **No autocorrelación:** $\text{Cov}(u_i, u_j|X) = 0$ para todo $i \neq j$.

.....
Teorema de Gauss-Markov: *Bajo los supuestos 1 a 6, los estimadores MCO son MELI (Mejor Estimador Lineal Insesgado) o BLUE (Best Linear Unbiased Estimator). Es decir, tienen varianza mínima dentro de la clase de estimadores lineales e insesgados.* [PDF + 1](#)

Varianza de los Estimadores y Error Estándar

$$\text{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sigma^2}{S_{XX}}$$

Como la varianza poblacional del error (σ^2) es desconocida, se estima con la varianza residual insesgada:

$$\hat{\sigma}^2 = s^2 = \frac{\text{SRC}}{n - k} = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - 2} \quad (k = \text{parámetros estimados} = 2)$$

$$\text{se}(\hat{\beta}_2) = \frac{\hat{\sigma}}{\sqrt{S_{XX}}}$$

5. Modelos de Transformación Logarítmica (Interpretación Práctica)

Se utilizan para captar relaciones no lineales manteniendo la linealidad en los parámetros:

Modelo	Ecuación	Interpretación Algebraica de β_1 PDF	Lectura Económica
Nivel - Nivel	$y = \beta_0 + \beta_1 x$ PDF	$\Delta y = \beta_1 \Delta x$ PDF	Si x sube 1 unidad, y varía β_1 unidades. PDF
Nivel - Log	$y = \beta_0 + \beta_1 \ln(x)$	$\Delta y = (\beta_1/100) \cdot \% \Delta x$ PDF	Si x sube 1%, y varía $(\beta_1/100)$ unidades. PDF
Log - Nivel	$\ln(y) = \beta_0 + \beta_1 x$	$\% \Delta y = (100 \cdot \beta_1) \cdot \Delta x$ PDF	Si x sube 1 unidad, y varía $(100 \cdot \beta_1)\%$ (semielasticidad). PDF
Log - Log	$\ln(y) = \beta_0 + \beta_1 \ln(x)$	$\% \Delta y = \beta_1 \cdot \% \Delta x$ PDF	Si x sube 1%, y varía $\beta_1\%$ (elasticidad constante). PDF

Nota para wage1 (Mincer): El modelo $\ln(\text{wage}) = \beta_0 + \beta_1 \text{educ} + u$ es un modelo **log-nivel**; por ende, $\beta_1 \times 100$ representa el retorno porcentual por cada año adicional de educación.

6. Pruebas de Hipótesis e Inferencia Estadística

Bajo el supuesto de normalidad de las perturbaciones ($u \sim \mathcal{N}(0, \sigma^2)$): [PDF](#)

Test t (Significatividad Individual)

- Hipótesis: $H_0 : \beta_j = 0$ frente a $H_1 : \beta_j \neq 0$
- Estadístico de prueba:

$$t_{\text{calc}} = \frac{\hat{\beta}_j - 0}{\text{se}(\hat{\beta}_j)} \sim t_{(n-k)}$$

- Regla de decisión: Se rechaza H_0 si $|t_{\text{calc}}| > t_{\alpha/2, n-k}$ o si el p -valor $< \alpha$.

Test F (Significatividad Global del Modelo)

- Hipótesis: $H_0 : \beta_2 = \beta_3 = \dots = \beta_k = 0$ frente a $H_1 : \text{Al menos un } \beta_j \neq 0$
- Estadístico de prueba:

$$F_{\text{calc}} = \frac{\text{SEC}/(k-1)}{\text{SRC}/(n-k)} = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{(k-1, n-k)}$$

- En regresión lineal simple ($k = 2$): $F = t^2$.

1. Wooldridge – Capítulo 2 (Secciones 2.1 a 2.4)

2. Wooldridge – Capítulo 4 (Secciones 4.1, 4.2 y 4.5)

3. Wooldridge – Capítulo 3 (Sección 3.6: Teorema de Gauss-Markov)

4. Gujarati & Porter – Capítulo 2 (Secciones 2.1 a 2.4): Leé únicamente la distinción entre FRP y FRM y el significado del error estocástico u_i vs. el residuo $\hat{u}_i$.

5. Wooldridge – Capítulo 4 (Sección 4.6): Interpretación rápida de pruebas de hipótesis con combinaciones lineales (ej. testear si dos coeficientes son iguales: $H_0: \beta_1 = \beta_2$).