

Resumen de Estudio: Econometría – Clase 3 (Regresión Múltiple: Especificación del Modelo)

1. Núcleo Conceptual: Especificación y Efecto Marginal

- **Principio de Parsimonia:** El modelo debe tener fundamento en la teoría económica y explicar la mayor variabilidad posible con el menor número necesario de parámetros (evitar sobreparametrización innecesaria). PDF
- **Interpretación *Ceteris Paribus* (Efecto Parcial o Marginal):**
En el modelo poblacional:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + u$$

El coeficiente β_j representa el cambio esperado en Y ante una variación unitaria en X_j , **manteniendo constantes todas las demás variables explicativas** del modelo ($\frac{\partial Y}{\partial X_j} = \beta_j$). PDF

2. Desarrollo Algebraico: Errores de Especificación

A. Omisión de Variables Relevantes (Sesgo por Variable Omitida)

- **Modelo Verdadero (Poblacional):** $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$
PDF
- **Modelo Estimado (Subespecificado):** $\tilde{Y} = \tilde{\beta}_0 + \tilde{\beta}_1 X_1 + \tilde{u}$
- **Regresión Auxiliar de X_2 sobre X_1 :** $X_2 = \tilde{\delta}_0 + \tilde{\delta}_1 X_1 + v$, donde $\tilde{\delta}_1 = \frac{\widehat{\text{Cov}(X_1, X_2)}}{\widehat{\text{Var}(X_1)}}$

Esperanza matemática del estimador:

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \cdot \tilde{\delta}_1$$

$$\text{Sesgo}(\tilde{\beta}_1) = \beta_2 \cdot \frac{\text{Cov}(\mathbf{X}_1, \mathbf{X}_2)}{\text{Var}(\mathbf{X}_1)}$$

Condición

Consecuencia en el estimador $\tilde{\beta}_1$

$\beta_2 = 0$ (X_2 no pertenece al modelo verdadero)

Insesgado: $E(\tilde{\beta}_1) = \beta_1$

$\text{Cov}(X_1, X_2) = 0$ (X_1 y X_2 están incorrelacionadas)

Insesgado: $E(\tilde{\beta}_1) = \beta_1$

$\beta_2 \neq 0$ y $\text{Cov}(X_1, X_2) \neq 0$

Sesgado e inconsistente (el signo del sesgo depende de los signos de β_2 y $\text{Cov}(X_1, X_2)$)

B. Inclusión de Variables Irrelevantes o Redundantes

- **Modelo Verdadero:** $Y = \beta_0 + \beta_1 X_1 + u$
- **Modelo Estimado (Sobreespecificado):** $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$, donde poblacionalmente $\beta_2 = 0$. [PDF](#)
- **Consecuencia:** Los estimadores siguen siendo **insesgados** ($E(\hat{\beta}_1) = \beta_1$), pero se **infla la varianza muestral** ($\text{Var}(\hat{\beta}_1)$ aumenta debido a la multicolinealidad con X_2):

[PDF](#)

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\text{SST}_1(1 - R_1^2)}$$

(Al incluir X_2 , $R_1^2 > 0$, lo que reduce la precisión y la potencia de los tests t).

3. No Linealidades: Polinomios e Interacciones

A. Términos Cuadráticos y Polinomiales

Permiten capturar rendimientos marginales crecientes o decrecientes (ej. ecuaciones salariales de Mincer con experiencia):

[PDF](#)

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$$

- **Efecto marginal (Derivada parcial):**

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$

El efecto de X sobre Y depende del nivel inicial de X . [PDF](#)

- **Punto de inflexión / Punto crítico:**

$$X^* = -\frac{\beta_1}{2\beta_2}$$

- Si $\beta_1 > 0$ y $\beta_2 < 0$: Curva cóncava ($\cap$), X^* es un **máximo** (ej. experiencia vs. salario).
- Si $\beta_1 < 0$ y $\beta_2 > 0$: Curva convexa ($\cup$), X^* es un **mínimo**.

B. Términos de Interacción

Permiten que el efecto marginal de una variable dependa del valor de otra:

PDF

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 \cdot X_2) + u$$

- Efecto marginal de X_1 :

$$\frac{\partial Y}{\partial X_1} = \beta_1 + \beta_3 X_2$$

- El impacto de X_1 sobre Y no es constante; se evalúa típicamente en la media de X_2 ($\bar{X}_2$) o en valores de interés.

4. Variables Categóricas / Ficticias (*Dummies*)

Variables binarias que toman valores $\{0, 1\}$ para modelar atributos cualitativos (género, región, tratamiento):

PDF

$$Y = \beta_0 + \delta_0 D + \beta_1 X + u, \quad D \in \{0, 1\}$$

- **Categoría base o de referencia** ($D = 0$): $E(Y|D = 0, X) = \beta_0 + \beta_1 X$
- **Categoría analizada** ($D = 1$): $E(Y|D = 1, X) = (\beta_0 + \delta_0) + \beta_1 X$
- **Interpretación**: δ_0 mide la **diferencia promedio constante** entre ambos grupos, manteniendo X fijo.
- **Trampa de la variable dicotómica (*Dummy Variable Trap*)**: Si una cualidad tiene m categorías, deben incluirse como máximo $m - 1$ **variables dummy** si el modelo tiene ordenada al origen (β_0). Incluir las m dummies genera **colinealidad perfecta**, imposibilitando invertir la matriz de datos para calcular MCO. PDF

5. Criterios de Selección de Modelos y Bondad de Ajuste

El R^2 convencional tiene una limitación matemática: **nunca decrece al añadir un nuevo regresor** (SRC solo puede bajar o mantenerse).

A. Coeficiente de Determinación Ajustado ($\bar{R}^2$)

Penaliza por la pérdida de grados de libertad al agregar variables adicionales:

$$\bar{R}^2 = 1 - \frac{SRC/(n - k - 1)}{STC/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

- $\bar{R}^2$ solo aumenta si el estadístico t de la variable agregada es en valor absoluto mayor a 1 ($|t| > 1$).
- Puede tomar valores negativos si el ajuste es muy deficiente.

B. Criterios de Información (AIC y BIC)

Se utilizan para comparar modelos anidados o no anidados. Se prefiere el modelo con menor valor del criterio: [PDF](#)

- Criterio de Akaike (AIC):

$$AIC = \ln \left(\frac{SRC}{n} \right) + \frac{2k}{n}$$

- Criterio Bayesiano / Schwarz (BIC):

$$BIC = \ln \left(\frac{SRC}{n} \right) + \frac{k \cdot \ln(n)}{n}$$

(El BIC impone una penalización más fuerte que el AIC por parámetro adicional cuando $n \geq 8$).

6. Pruebas de Hipótesis: Restricciones de Igualdad

Para contrastar hipótesis lineales que vinculan dos o más coeficientes (ej. $H_0: \beta_1 = \beta_2$ frente a $H_1: \beta_1 \neq \beta_2$):

A. Vía Test t (Uniparamétrico)

Reescribiendo la hipótesis nula como $\theta = \beta_1 - \beta_2 = 0$:

$$t = \frac{\hat{\beta}_1 - \hat{\beta}_2}{\text{se}(\hat{\beta}_1 - \hat{\beta}_2)} \sim t_{(n-k-1)}$$

Donde el error estándar de la combinación lineal requiere considerar la covarianza:

$$\text{Var}(\hat{\beta}_1 - \hat{\beta}_2) = \text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_2) - 2\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)$$

$$\text{se}(\hat{\beta}_1 - \hat{\beta}_2) = \sqrt{\text{Var}(\hat{\beta}_1 - \hat{\beta}_2)}$$

B. Vía Test F (Modelo Restringido vs. No Restringido)

$$F_{\text{calc}} = \frac{(\text{SRC}_R - \text{SRC}_{NR})/q}{\text{SRC}_{NR}/(n-k-1)} = \frac{(R_{NR}^2 - R_R^2)/q}{(1 - R_{NR}^2)/(n-k-1)} \sim F_{(q, n-k-1)}$$

- q : Número de restricciones lineales impuestas bajo H_0 (si se testea $\beta_1 = \beta_2$, $q = 1$).
- Regla de decisión: Si $F_{\text{calc}} > F_{\text{crítico}}$, se rechaza H_0 de igualdad de coeficientes.

7. Comandos de STATA Relevantes para la Práctica

(Vinculados a las bases *wage1*, *gpa1*, *hprice2*, *401ksubs*, *ceosal2*):

- Generar término cuadrático tradicional: `gen xsq = x^2`.
- Sintaxis moderna de factores/interacciones:
 - Variable categórica: `i.female`
 - Interacción entre cuantitativa y categórica: `c.educ#i.female`
 - Modelo completo con efectos lineales e interactivos: `c.exper##c.exper` o `c.educ##i.female`
- Test de restricciones de igualdad tras correr `regress`: `test educ = exper` o `test beta1 - beta2 = 0`

1. Wooldridge – Capítulo 6 (Prioridad Absoluta) 6.1 6.2 6.3

2. Wooldridge – Capítulo 4 (Sección 4.4 y 4.6)

3. Wooldridge – Capítulo 9 (Sección 9.1 y 9.2)

4. Gujarati & Porter – Capítulo 13